



2025年度工作总结： 构筑新一代AI模型评测引擎

为模型研发打造坚实、高效、全面的技术基石

2025年度核心成果：从体系构建到价值创造



体系化建设

- 主导构建了覆盖文本与多模态的全链条评测能力。
- 整合 **18+** 个文本评测基准，形成标准化流程。
- 从0到1研发 **13** 个多模态评测榜单，填补能力空白。



颠覆式增效

- 7天** → **30小时**
将核心科学推理评测周期从7天 压缩至 30小时。
- 将需 **4人** 协作的复杂评测任务，整合为可独立高效执行。



战略性支撑

- 累计完成 **100+** 内外部模型的全面评测。
- 输出多个关键评测结论，为模型迭代优化提供了核心数据支撑。


始于目标：支撑快速迭代，需构建更强大的评测能力

核心目标

围绕公司模型研发战略，搭建一套标准化、高效率、广覆盖的评测体系。

三大关键支柱


1. **核心模型评测任务**：保障开源及内部主线模型的日常评测与性能摸底。
2. **评测基准构建与开发**：体系化集成文本基准，并从零开始研发多模态评测能力。
3. **协同支撑与工作对接**：确保跨团队工作高效衔接，同步评测环境与资源。




体系升级：从分散到整合，实现评测效率聚变

统一文本评测口径，将重复劳动转化为可复用的核心能力

分散式流程



一体化流程



整合范围

高效集成 **18个** 核心文本评测基准，覆盖四大关键领域。

- 科学推理：12个 (e.g., SciBench, ProteinLMBench)
- 数学能力：4个
- 长文本能力：3个 (e.g., ClongEval, InfiniteBench)
- 指令遵循：1个

核心举措

流程再造：设计并落地标准化、可复用的评测流程与操作规范。

环境搭建：完成各基准的专属环境搭建与适配。

一体化管理：实现多类型文本评测基准的统一调度与管理。

评测效率的量级提升：7天到30小时的飞跃

传统分散式评测


7天

评测周期

≥4人

协作成本

流程繁琐，口径不一，沟通成本高



一体化评测体系

30小时

评测周期

1人

高效执行

流程标准，结果可靠，协作成本大幅降低

能力突破：从0到1，构筑多模态评测新版图

聚焦前沿领域，成功落地体系化的多模态模型评测能力

技术选型

深入调研并选用 **VLMEvalKit** 作为核心开发框架。

框架攻坚

成功完成框架的自定义数据集适配、调试及本地化改造。

体系构建


完成框架内置榜单的全面调试与验证。

自主研发 **13个** 全新多模态评测榜单，如 **ScienceOlympiad**、**GMAI-MMBench** 等。


建立并完善了多模态模型的关键评测指标体系。

成果沉淀

实现了评测流程的标准化与操作手册化。



成果集成：建成覆盖文本到多模态的全链条评测引擎



评测能力版图：覆盖关键领域的基准清单

评测领域	核心基准	状态
科学推理	SciBench, ProteinLMBench, Physics, 及其余9个科学推理基准	✔ 已集成/已开发
长文本	CLongEval, InfiniteBench, 及其余1个长文本基准	✔ 已集成/已开发
数学	4个核心数学能力基准	✔ 已集成/已开发
多模态	MMMU, ScienceOlympiad, GMAI-MMBench, XLRIS-Bench, 及其余9个多模态基准	✔ 已集成/已开发

复盘与沉淀：成长源于挑战

总结经验与教训，将过程中的难点转化为团队的宝贵资产



关键挑战复盘与应对策略

挑战一：技术预研深度不足

情景 (Situation)： 某科学文献基准开发时，因预研不充分，未能预判其不支持多模型并行评测等适配难点，导致集成延期。

行动 (Action)： 重新评估技术方案，调整集成优先级。

沉淀 (Learning)： 面对新框架、新领域，必须将技术预研前置，提前识别核心难点并制定应对方案，这是提升效率的关键。

挑战二：开源框架适配与源码修改


情景 (Situation)： 适配VLMEvaKit时，遇到数据集测试不通、本地接口调用报错、源码抽取规则不完善导致分数异常等难题。

行动 (Action)： 通过反复调试代码、查阅官方文档、修改源码以适配本地接口、优化抽取逻辑，最终解决所有问题，精准复现实验分数。

沉淀 (Learning)： 复杂的开源框架适配需要扎实的技术功底和持续的攻坚精神。

未来蓝图：从评测引擎到自动化流水线

推动评测体系的下一阶段进化，实现更高层次的效率与价值



2026年重点工作计划



平台化：搭建统一评测底座

整合文本与多模态评测能力，搭建统一、可视化的评测平台。

目标：大幅减少重复开发工作，实现评测流程的自动化。



知识化：沉淀核心技术资产

建立开源框架技术知识库，系统沉淀适配难点、解决方案与最佳实践。

目标：赋能团队，提升整体技术储备与效率。



专业化：深化个人技术深度

深度参与多模态评测优化、自动化流水线搭建等核心项目。

力争在知识产权方面产出 **1-2 篇** 专利。

同频共振，协同提升

2025年，我不仅完成了评测任务，更是为团队构建了一项核心技术资产。

2026年，我将致力于将这项资产升级为驱动模型高效研发的自动化流水线，实现个人成长与公司发展的协同共进。